



多传感器融合定位

第4章 基于滤波的融合方法

主讲人 任 乾

北京理工大学本硕
自动驾驶从业者





目录



1. 滤波器作用



2. 概率基础知识



3. 滤波器基本原理



4. 基于滤波器的融合



5. 观测性与观测度分析



目录



1. 滤波器作用



2. 概率基础知识



3. 滤波器基本原理



4. 基于滤波器的融合



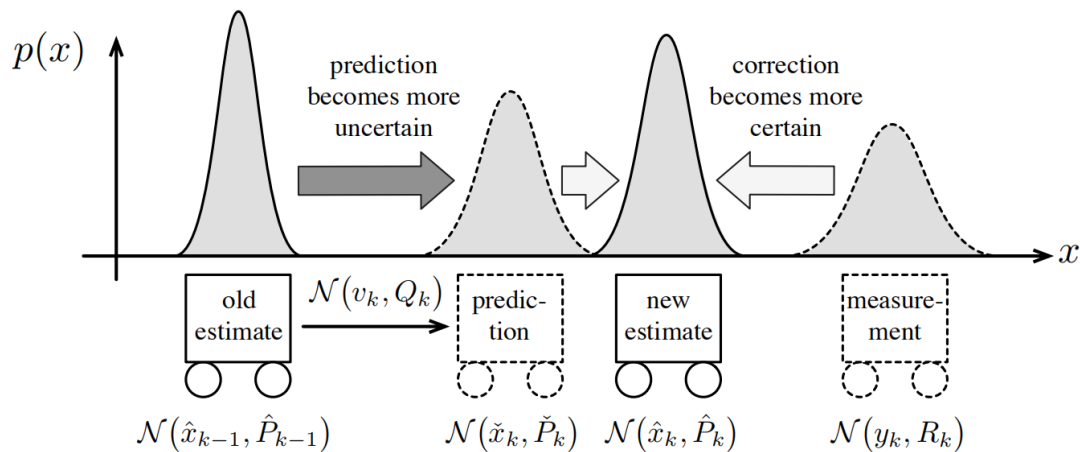
5. 观测性与观测度分析



滤波器作用

滤波器的本质：结合预测与观测，得到最“精确”的后验值。

实际中，预测与观测均从传感器而来，因此滤波器的作用便是结合各传感器得到一个最好的融合结果。



- 1) 实际中预测往往从IMU、编码器等传感器递推而来；
- 2) 观测往往从GPS、雷达、相机等传感器而来；
- 3) 后验为融合后的结果，即定位模块的输出。



目录



1. 滤波器作用



2. 概率基础知识



3. 滤波器基本原理



4. 基于滤波器的融合




5. 观测性与观测度分析



概率基础知识

1. 概率、概率密度



上图中, $p(x)$ 为 x 在区间 $[a, b]$ 上的**概率密度**, 它表示的是随机变量在区间的分布情况。

\Pr 代表的是 x 在区间 $[c, d]$ 上的**概率**, 它是概率密度的积分,

$$\Pr(c \leq x \leq d) = \int_c^d p(x) dx$$

我们平时所说“高斯分布”、“非高斯分布”均是指它的概率密度。



概率基础知识

2. 联合概率

$x \in [a, b]$ 和 $y \in [r, s]$ 的联合概率密度函数可以表示为 $p(x, y)$ ，其积分表示 x 和 y 同时处在某个区间的概率，满足下式：

$$\int_a^b \int_r^s p(x, y) dy dx = 1$$

特别地，当 x 和 y 统计独立的时候，有

$$p(x, y) = p(x)p(y)$$

3. 条件概率

x 关于 y 的条件概率密度函数可以表示为

$$p(x | y)$$

其含义是，在 $y \in [r, s]$ 的前提下， $x \in [a, b]$ 的概率分布，并且满足下式

$$p(x) = \int_r^s p(x | y) p(y) dy$$

特别地，当 x 和 y 统计独立的时候，有

$$p(x | y) = p(x)$$



概率基础知识

4. 贝叶斯公式

联合概率分解成条件概率和边缘概率的乘积，即

$$p(x, y) = p(x | y)p(y) = p(y | x)p(x)$$

重新整理，即可得贝叶斯公式

$$p(x | y) = \frac{p(y|x)p(x)}{p(y)}$$

5. 贝叶斯推断

贝叶斯推断可以理解为贝叶斯公式的运用，它是指，如果已知**先验**概率密度函数 $p(x)$ ，以及**传感器模型** $p(y | x)$ ，那么就可以根据贝叶斯公式**推断**出后验概率密度。

$$p(x | y) = \frac{p(y|x)p(x)}{\int p(y|x)p(x)dx}$$

实际中，贝叶斯推断有时也叫贝叶斯估计。



概率基础知识

6. 高斯概率密度函数

一维情况下，高斯概率密度函数表示为：

$$p(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x - \mu)^2}{\sigma^2}\right)$$

其中 μ 为均值， σ^2 为方差。

多维情况下，高斯概率密度函数表示为

$$p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^N \det \boldsymbol{\Sigma}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

其中均值为 $\boldsymbol{\mu}$ ，方差为 $\boldsymbol{\Sigma}$ 。

一般把高斯分布写成 $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。



概率基础知识

7. 联合高斯概率密度函数

若有高斯分布

$$p(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$$

$$p(\mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$$

则它们的联合概率密度函数可以表示为

$$p(\mathbf{x}, \mathbf{y}) = \mathcal{N}\left(\begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix}\right)$$

由于联合概率满足下式

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x} | \mathbf{y})p(\mathbf{y})$$

该式在高斯分布的前提下可以重新分解。

由于高斯分布中指数项包含方差的求逆，而此处联合概率的方差是一个高维矩阵，对它求逆的简洁办法是运用舒尔补。

舒尔补的主要目的是把矩阵分解成上三角矩阵、对角阵、下三角矩阵乘积的形式，方便运算，即

$$\begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} = \begin{bmatrix} \mathbf{I} & \mathbf{BD}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Delta\mathbf{D} & \mathbf{0} \\ \mathbf{0} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix}$$

其中 $\Delta\mathbf{D} = \mathbf{A} - \mathbf{BD}^{-1}\mathbf{C}$ 称为矩阵D关于原矩阵的舒尔补。

此时有

$$\begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix}^{-1} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Delta\mathbf{D}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{D}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & -\mathbf{BD}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix}$$



概率基础知识

7. 联合高斯概率密度函数

利用舒尔补，联合分布的方差矩阵可以写为

$$\begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix} = \begin{bmatrix} 1 & \Sigma_{xy}\Sigma_{yy}^{-1} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx} & 0 \\ 0 & \Sigma_{yy} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ \Sigma_{yy}^{-1}\Sigma_{yx} & 1 \end{bmatrix}$$

它的逆矩阵为

$$\begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix}^{-1} = \begin{bmatrix} 1 & 0 \\ -\Sigma_{yy}^{-1}\Sigma_{yx} & 1 \end{bmatrix} \begin{bmatrix} (\Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx})^{-1} & 0 \\ 0 & \Sigma_{yy}^{-1} \end{bmatrix} \begin{bmatrix} 1 & -\Sigma_{xy}\Sigma_{yy}^{-1} \\ 0 & 1 \end{bmatrix}$$



概率基础知识

7. 联合高斯概率密度函数

联合分布 $p(\mathbf{x}, \mathbf{y})$ 仍为高斯分布,

$$p(\mathbf{x}, \mathbf{y}) = \mathcal{N} \left(\begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix} \right)$$

它的指数部分的二次项包含如下内容

$$\begin{aligned} & \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right)^T \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix}^{-1} \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right) \\ &= \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right)^T \begin{bmatrix} \mathbf{1} & \mathbf{0} \\ -\boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx} & \mathbf{1} \end{bmatrix} \begin{bmatrix} (\boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx})^{-1} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_{yy}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{1} & -\boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \\ \mathbf{0} & \mathbf{1} \end{bmatrix} \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right) \\ &= (\mathbf{x} - \boldsymbol{\mu}_x - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y))^T (\boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx})^{-1} (\mathbf{x} - \boldsymbol{\mu}_x - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y)) \\ &\quad + (\mathbf{y} - \boldsymbol{\mu}_y)^T \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y) \end{aligned}$$

最后得到两个二次项的和, 由于同底数幂相乘后, 底数不变, 指数相加, 且 $p(\mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$

因此有 $p(\mathbf{x} | \mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_x + \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y), \boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx})$



概率基础知识

8. 高斯随机变量的线性分布

在上面的例子中，若已知 x 和 y 之间有如下关系

$$y = Gx + n$$

其中 G 是一个常量矩阵, $n = \mathcal{N}(0, R)$ 为零均值白噪声，在实际中指的是观测噪声。则 x 和 y 的均值和方差之间必然存在联系，其联系可通过以下推导获得。

均值

$$\begin{aligned}
\mu_y &= E[y] \\
&= E[Gx + n] \\
&= GE[x] + E[n] \\
&= G\mu_x
\end{aligned}$$

方差

$$\begin{aligned}
\Sigma_{yy} &= \Sigma(Gx) + \Sigma(n) \\
&= E \left[(Gx - \mu_y) (Gx - \mu_y)^T \right] + R \\
&= GE \left[(x - \mu_x) (x - \mu_x)^T \right] G^T + R \\
&= G\Sigma_{xx}G^T + R
\end{aligned}$$

方差的交叉项

$$\begin{aligned}
\Sigma_{xy} &= E \left[(x - \mu_x) (y - \mu_y)^T \right] \\
&= E \left[(x - \mu_x) (Gx - G\mu_x + n)^T \right] \\
&= E \left[(x - \mu_x) (Gx - G\mu_x)^T + (x - \mu_x) n^T \right] \\
&= \Sigma_{xx}G^T + E \left[(x - \mu_x) n^T \right] \\
&= \Sigma_{xx}G^T
\end{aligned}$$

同理可得 $\Sigma_{yx} = \Sigma_{xy}^T = G\Sigma_{xx}$



目录



1. 滤波器作用



2. 概率基础知识



3. 滤波器基本原理



4. 基于滤波器的融合



5. 观测性与观测度分析



滤波器基本原理

1. 状态估计模型

实际状态估计任务中，待估计的后验概率密度可以表示为：

$$p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k})$$

其中

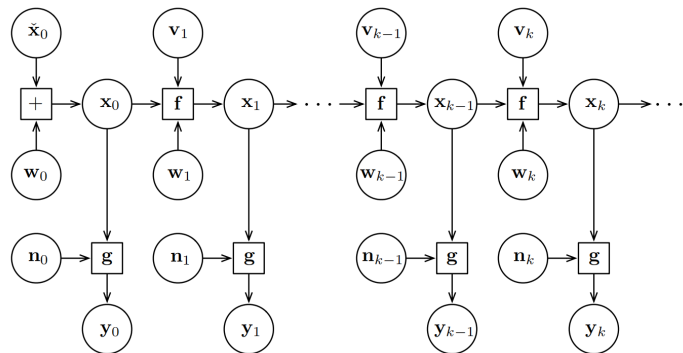
$\check{\mathbf{x}}_0$ 表示的是状态初始值

$\mathbf{v}_{1:k}$ 表示从1到k时刻的输入

$\mathbf{y}_{0:k}$ 表示从0到k时刻的观测

因此，滤波问题可以直观表示为，根据所有历史数据(输入、观测、初始状态)，得出最终的融合结果。

历史数据之间的关系，可以用下面的图模型表示，



图模型中体现了马尔可夫性，即当前状态只跟前一时刻状态相关，和其他历史时刻状态无关。数学表达该性质，

$$\text{运动方程: } \mathbf{x}_k = \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k)$$

$$\text{观测方程: } \mathbf{y}_k = \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k)$$



滤波器基本原理

2. 贝叶斯滤波

根据贝叶斯公式 k 时刻后验概率密度可以表示为

$$\begin{aligned}
 p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k}) &= \frac{p(\mathbf{y}_k \mid \mathbf{x}_k, \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1})}{p(\mathbf{y}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1})} \\
 &= \eta p(\mathbf{y}_k \mid \mathbf{x}_k, \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1})
 \end{aligned}$$

根据观测方程, \mathbf{y}_k 只和 \mathbf{x}_k 相关, 因此上式可以简写为

$$p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k}) = \eta p(\mathbf{y}_k \mid \mathbf{x}_k) p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1})$$

应用系统的马尔可夫性进一步化简公式,

$$\begin{aligned}
 &p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) \\
 &= \int p(\mathbf{x}_k, \mathbf{x}_{k-1} \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) d\mathbf{x}_{k-1} \\
 &= \int p(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) p(\mathbf{x}_{k-1} \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) d\mathbf{x}_{k-1} \\
 &= \int p(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{v}_k) p(\mathbf{x}_{k-1} \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) d\mathbf{x}_{k-1}
 \end{aligned}$$



滤波器基本原理

2. 贝叶斯滤波

经过以上化简，最终后验概率可以写为

$$\underbrace{p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k})}_{\text{estimate}} \\ = \eta \underbrace{p(\mathbf{y}_k \mid \mathbf{x}_k)}_{g(\cdot)} \int \underbrace{p(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{v}_k)}_{f(\cdot)} \underbrace{p(\mathbf{x}_{k-1} \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{0:k-1})}_{\text{last estimate}} d\mathbf{x}_{k-1}$$

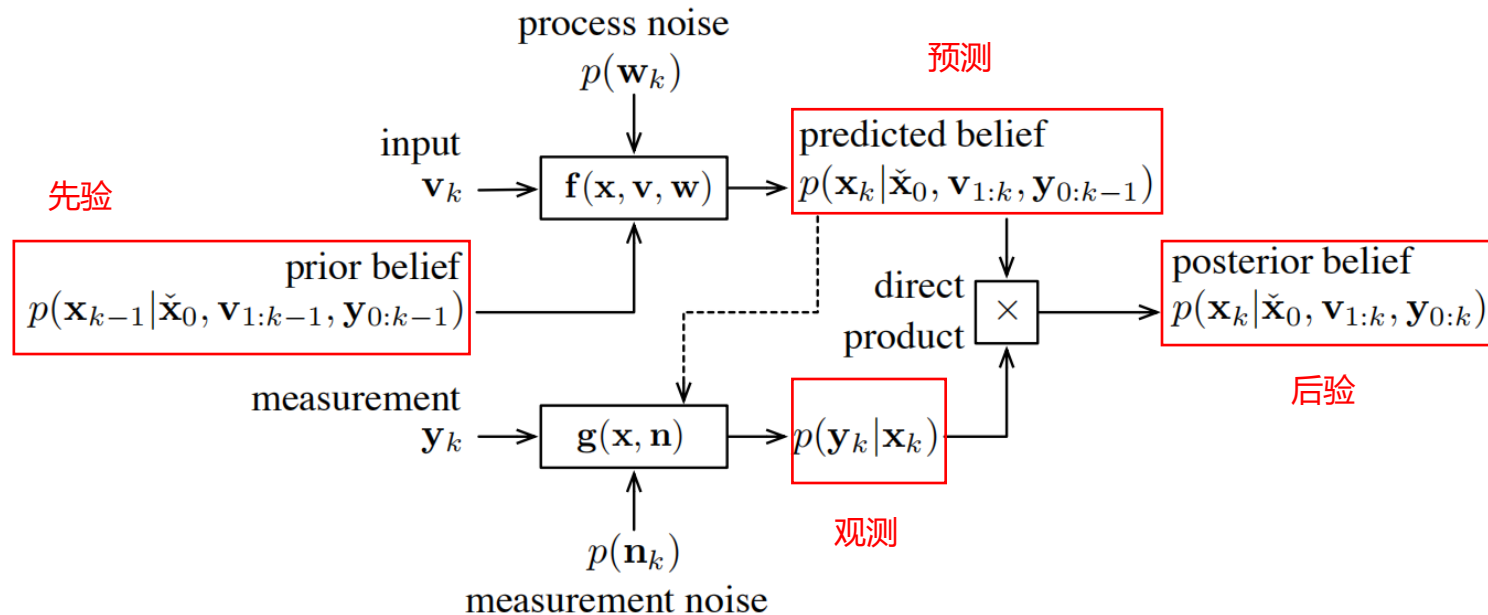
观测 预测 先验



滤波器基本原理

2. 贝叶斯滤波

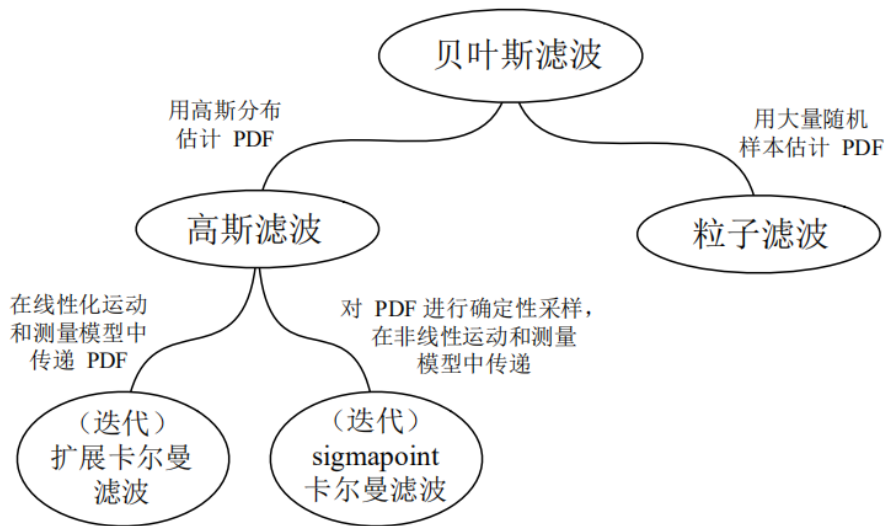
根据以上结果，可以画出贝叶斯滤波的信息流图如下





滤波器基本原理

2. 贝叶斯滤波



1) 在高斯假设前提下，用贝叶斯滤波的原始形式比较复杂，可以利用高斯的特征得到简化形式，即广义高斯滤波，后面KF、EKF、IEKF、UKF的推导均采用这种形式，只有PF例外，因为它是针对非高斯的。

2) 实际中，粒子滤波多用于(早期的)2D激光SLAM方案中，不属于本门课程讲解重点，因此只做原理介绍。



滤波器基本原理

3. 卡尔曼滤波(KF)推导

在线性高斯假设下，上式可以重新写为下面的形式(为了和后面符号对应)

$$\text{运动方程: } \mathbf{x}_k = \mathbf{F}(\mathbf{x}_{k-1}, \mathbf{v}_k) + \mathbf{B}_{k-1}\mathbf{w}_k$$

$$\text{观测方程: } \mathbf{y}_k = \mathbf{G}(\mathbf{x}_k) + \mathbf{C}_k\mathbf{n}_k$$

把上一时刻的后验状态写为

$$p(\mathbf{x}_{k-1} \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{0:k-1}) = \mathcal{N}(\hat{\mathbf{x}}_{k-1}, \hat{\mathbf{P}}_{k-1})$$

则当前时刻的预测值为

$$\check{\mathbf{x}}_k = \mathbf{F}(\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k)$$

根据高斯分布的线性变化，它的方差为

$$\check{\mathbf{P}}_k = \mathbf{F}_{k-1}\hat{\mathbf{P}}_{k-1}\mathbf{F}_{k-1}^T + \mathbf{B}_{k-1}\mathbf{Q}_k\mathbf{B}_{k-1}^T$$

其中 \mathbf{Q}_k 为当前输入噪声的方差。



滤波器基本原理

3. 卡尔曼滤波(KF)推导

若把 k 时刻状态和观测的联合高斯分布写为

$$p(\mathbf{x}_k, \mathbf{y}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) = \mathcal{N} \left(\begin{bmatrix} \boldsymbol{\mu}_{x,k} \\ \boldsymbol{\mu}_{y,k} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx,k} & \boldsymbol{\Sigma}_{xy,k} \\ \boldsymbol{\Sigma}_{yx,k} & \boldsymbol{\Sigma}_{yy,k} \end{bmatrix} \right)$$

根据第1节7)中的推导结果, k 时刻的后验概率可以写为

$$\begin{aligned} p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k}) \\ = \mathcal{N}(\underbrace{\boldsymbol{\mu}_{x,k} + \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1} (\mathbf{y}_k - \boldsymbol{\mu}_{y,k})}_{\hat{\mathbf{x}}_k}, \underbrace{\boldsymbol{\Sigma}_{xx,k} - \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1} \boldsymbol{\Sigma}_{yx,k}}_{\hat{\mathbf{P}}_k}) \end{aligned}$$

其中 $\hat{\mathbf{x}}_k$ 和 $\hat{\mathbf{P}}_k$ 分别为后验均值和方差。若定义

$$\mathbf{K}_k = \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1}$$

则有

$$\begin{aligned} \hat{\mathbf{P}}_k &= \check{\mathbf{P}}_k - \mathbf{K}_k \boldsymbol{\Sigma}_{xy,k}^T \\ \hat{\mathbf{x}}_k &= \check{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - \boldsymbol{\mu}_{y,k}) \end{aligned}$$



滤波器基本原理

3. 卡尔曼滤波(KF)推导

把第1节8)中的推导得出的线性变换后的均值、方差及交叉项带入上面的式子，可以得到：

$$\mathbf{K}_k = \check{\mathbf{P}}_k \mathbf{G}_k^T (\mathbf{G}_k \check{\mathbf{P}}_k \mathbf{G}_k^T + \mathbf{C}_k \mathbf{R}_k \mathbf{C}_k^T)^{-1}$$

$$\hat{\mathbf{P}}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{G}_k) \check{\mathbf{P}}_k$$

$$\hat{\mathbf{x}}_k = \check{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - \mathbf{G}(\check{\mathbf{x}}_k))$$

上面方程与之前所述预测方程(如下)，就构成了卡尔曼经典五个方程。

$$\check{\mathbf{x}}_k = \mathbf{F}(\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k)$$

$$\check{\mathbf{P}}_k = \mathbf{F}_{k-1} \hat{\mathbf{P}}_{k-1} \mathbf{F}_{k-1}^T + \mathbf{B}_{k-1} \mathbf{Q}_k \mathbf{B}_{k-1}^T$$

需要说明的是，若不把第1节8)中的结果带入，而保留上页的原始形式，则对应的五个方程被称为广义高斯滤波。



滤波器基本原理

4. 扩展卡尔曼滤波(EKF)推导

当运动方程或观测方程为非线性的时候，无法再利用之前所述的线性变化关系进行推导，常用的解决方法是进行线性化，把非线性方程一阶泰勒展开成线性。即

$$\text{运动方程: } \mathbf{x}_k = \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k) \approx \check{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + \mathbf{B}_{k-1}\mathbf{w}_k$$

$$\text{观测方程: } \mathbf{y}_k = \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k) \approx \check{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \check{\mathbf{x}}_k) + \mathbf{C}_k\mathbf{n}_k$$

其中

$$\check{\mathbf{x}}_k = \mathbf{f}(\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k, \mathbf{0})$$

$$\check{\mathbf{y}}_k = \mathbf{g}(\check{\mathbf{x}}_k, \mathbf{0})$$

$$\mathbf{F}_{k-1} = \left. \frac{\partial \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k)}{\partial \mathbf{x}_{k-1}} \right|_{\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k, \mathbf{0}}$$

$$\mathbf{G}_k = \left. \frac{\partial \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k)}{\partial \mathbf{x}_k} \right|_{\check{\mathbf{x}}_k, \mathbf{0}}$$

$$\mathbf{B}_{k-1} = \left. \frac{\partial \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k)}{\partial \mathbf{w}_k} \right|_{\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k, \mathbf{0}}$$

$$\mathbf{C}_k = \left. \frac{\partial \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k)}{\partial \mathbf{n}_k} \right|_{\check{\mathbf{x}}_k, \mathbf{0}}$$



滤波器基本原理

4. 扩展卡尔曼滤波(EKF)推导

根据该线性化展开结果，可以得到**预测状态**的统计学特征为

$$E[\mathbf{x}_k] \approx \check{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + \underbrace{E[\mathbf{B}_{k-1}\mathbf{w}_k]}_0$$

$$E[(\mathbf{x}_k - E[\mathbf{x}_k])(\mathbf{x}_k - E[\mathbf{x}_k])^T] \approx \underbrace{E[\mathbf{B}_{k-1}\mathbf{w}_k\mathbf{w}_k^T\mathbf{B}_{k-1}^T]}_{\mathbf{B}_{k-1}\mathbf{Q}_k\mathbf{B}_{k-1}^T}$$

$$\text{即 } p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{v}_k) \approx \mathcal{N}(\check{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}), \mathbf{B}_{k-1}\mathbf{Q}_k\mathbf{B}_{k-1}^T)$$

同理，可得到**观测**的统计学特征为

$$E[\mathbf{y}_k] \approx \check{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \check{\mathbf{x}}_k) + \underbrace{E[\mathbf{C}_k\mathbf{n}_k]}_0$$

$$E[(\mathbf{y}_k - E[\mathbf{y}_k])(\mathbf{y}_k - E[\mathbf{y}_k])^T] \approx \underbrace{E[\mathbf{C}_k\mathbf{n}_k\mathbf{n}_k^T\mathbf{C}_k^T]}_{\mathbf{C}_k\mathbf{R}_k\mathbf{C}_k^T}$$

$$\text{即 } p(\mathbf{y}_k | \mathbf{x}_k) \approx \mathcal{N}(\check{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \check{\mathbf{x}}_k), \mathbf{C}_k\mathbf{R}_k\mathbf{C}_k^T)$$



滤波器基本原理

4. 扩展卡尔曼滤波(EKF)推导

后面即可按照线性高斯下推导卡尔曼滤波的步骤进行推导，最终得到经典五个公式

$$\check{P}_k = F_{k-1} \hat{P}_{k-1} F_{k-1}^T + B_{k-1} Q_k B_{k-1}^T$$

$$\check{x}_k = f(\hat{x}_{k-1}, v_k, 0)$$

$$K_k = \check{P}_k G_k^T (G_k \check{P}_k G_k^T + C_k R_k C_k^T)^{-1}$$

$$\hat{P}_k = (I - K_k G_k) \check{P}_k$$

$$\hat{x}_k = \check{x}_k + K_k (y_k - g(\check{x}_k, 0))$$



滤波器基本原理

5. 迭代扩展卡尔曼滤波(IEKF)推导

由于非线性模型中做了线性化近似，当非线性程度越强时，误差就会较大，但是由于线性化的工作点离真值越近，线性化的误差就越小，因此解决该问题的一个方法是，通过迭代逐渐找到准确的线性化点，从而提高精度。

在EKF的推导中，其他保持不变，仅改变观测的线性化工作点，则有

$$g(x_k, n_k) \approx y_{\text{op},k} + G_k(x_k - x_{\text{op},k}) + C_k n_k$$

其中

$$y_{\text{op},k} = g(x_{\text{op},k}, 0)$$

$$G_k = \left. \frac{\partial g(x_k, n_k)}{\partial x_k} \right|_{x_{\text{op},k}, 0}$$

$$C_k = \left. \frac{\partial g(x_k, n_k)}{\partial n_k} \right|_{x_{\text{op},k}, 0}$$



滤波器基本原理

5. 迭代扩展卡尔曼滤波(IEKF)推导

按照与之前同样的方式进行推导，可得到滤波的校正过程为

$$\mathbf{K}_k = \check{\mathbf{P}}_k \mathbf{G}_k^T (\mathbf{G}_k \check{\mathbf{P}}_k \mathbf{G}_k^T + \mathbf{C}_k \mathbf{R}_k \mathbf{C}_k^T)^{-1}$$

$$\hat{\mathbf{P}}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{G}_k) \check{\mathbf{P}}_k$$

$$\hat{\mathbf{x}}_k = \check{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - \mathbf{y}_{\text{op},k} - \mathbf{G}_k (\check{\mathbf{x}}_k - \mathbf{x}_{\text{op},k}))$$

可见唯一的区别是后验均值 $\hat{\mathbf{x}}_k$ 更新的公式与之前有所不同。


滤波过程中，反复执行上面3个公式，以上次的后验均值作为本次的线性化工作点，即可达到减小非线性误差的目的。



滤波器基本原理

6. sigmapoint卡尔曼滤波(UKF/SPKF)推导

该方法的核心思想是，通过采样一部分sigmapoint点，传入非线性函数，通过计算这些点的分布，来近似概率密度函数。





滤波器基本原理

1)sigmapoint变换原理

a. 根据输入概率密度 $\mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$ 计算出 $2L + 1$ 个 sigmapoint, 即

$$\boldsymbol{L}\boldsymbol{L}^T = \boldsymbol{\Sigma}_{xx} \quad (\text{Cholesky分解, } \boldsymbol{L} \text{ 为下三角矩阵})$$

$$\boldsymbol{x}_0 = \boldsymbol{\mu}_x$$

$$\boldsymbol{x}_i = \boldsymbol{\mu}_x + \sqrt{L + \kappa} \text{col}_i \boldsymbol{L}$$

$$\boldsymbol{x}_{i+L} = \boldsymbol{\mu}_x - \sqrt{L + \kappa} \text{col}_i \boldsymbol{L}$$

其中

$$\boldsymbol{\mu}_x = \sum_{i=0}^{2L} \alpha_i \boldsymbol{x}_i$$

$$\boldsymbol{\Sigma}_{xx} = \sum_{i=0}^{2L} \alpha_i (\boldsymbol{x}_i - \boldsymbol{\mu}_x) (\boldsymbol{x}_i - \boldsymbol{\mu}_x)^T$$

$$\alpha_i = \begin{cases} \frac{\kappa}{L+\kappa} & i = 0 \\ \frac{1}{2(L+\kappa)} & \text{others} \end{cases}$$

b. 把每个sigmapoint单独带入非线性函数 $\boldsymbol{g}(\boldsymbol{q})$ 中;

$$\boldsymbol{y}_i = \boldsymbol{g}(\boldsymbol{x}_i), \quad i = 0 \dots 2L$$

c. 输出概率的均值通过下面的式子计算;

$$\boldsymbol{\mu}_y = \sum_{i=0}^{2L} \alpha_i \boldsymbol{y}_i$$

d. 输出概率的协方差通过下面的式子计算。

$$\boldsymbol{\Sigma}_{yy} = \sum_{i=0}^{2L} \alpha_i (\boldsymbol{y}_i - \boldsymbol{\mu}_y) (\boldsymbol{y}_i - \boldsymbol{\mu}_y)^T$$



滤波器基本原理

2) 预测步骤

a. 把先验置信度和运动噪声按如下方式堆叠到一起

$$\boldsymbol{\mu}_z = \begin{bmatrix} \hat{\boldsymbol{x}}_{k-1} \\ \mathbf{0} \end{bmatrix}$$

$$\boldsymbol{\Sigma}_{zz} = \begin{bmatrix} \hat{\boldsymbol{P}}_{k-1} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{Q}_k \end{bmatrix}$$

b. 将 $\{\boldsymbol{\mu}_z, \boldsymbol{\Sigma}_{zz}\}$ 转化为sigmapoint表示

$$\boldsymbol{L}\boldsymbol{L}^T = \boldsymbol{\Sigma}_{zz}$$

$$\boldsymbol{z}_0 = \boldsymbol{\mu}_z$$

$$\boldsymbol{z}_i = \boldsymbol{\mu}_z + \sqrt{L + \kappa} \text{col}_i \boldsymbol{L}$$

$$\boldsymbol{z}_{i+L} = \boldsymbol{\mu}_z - \sqrt{L + \kappa} \text{col}_i \boldsymbol{L}$$

c. 对每个 sigmapoint 展开为状态和运动噪声的形式

$$\boldsymbol{z}_i = \begin{bmatrix} \hat{\boldsymbol{x}}_{k-1,i} \\ \boldsymbol{w}_{k,i} \end{bmatrix}$$

接着将每个 sigmapoint 代入非线性运动模型进行精确求解

$$\check{\boldsymbol{x}}_{k,i} = \boldsymbol{f}(\hat{\boldsymbol{x}}_{k-1,i}, \boldsymbol{v}_k, \boldsymbol{w}_{k,i}), \quad i = 0 \dots 2L$$

d. 将转换后的 sigmapoint 重新组合成预测置信度

$$\check{\boldsymbol{x}}_k = \sum_{i=0}^{2L} \alpha_i \check{\boldsymbol{x}}_{k,i}$$

$$\check{\boldsymbol{P}}_k = \sum_{i=0}^{2L} \alpha_i (\check{\boldsymbol{x}}_{k,i} - \check{\boldsymbol{x}}_k)(\check{\boldsymbol{x}}_{k,i} - \check{\boldsymbol{x}}_k)^T$$

其中

$$\alpha_i = \begin{cases} \frac{\kappa}{L + \kappa} & i = 0 \\ \frac{1}{2(L + \kappa)} & \text{others} \end{cases}$$



滤波器基本原理

3) 校正步骤

a. 把预测置信度和观测噪声按如下方式堆叠到一起

$$\boldsymbol{\mu}_z = \begin{bmatrix} \check{\mathbf{x}}_k \\ \mathbf{0} \end{bmatrix} \quad \boldsymbol{\Sigma}_{zz} = \begin{bmatrix} \check{\mathbf{P}}_k & \mathbf{0} \\ \mathbf{0} & \mathbf{R}_k \end{bmatrix}$$

b. 将 $\{\boldsymbol{\mu}_z, \boldsymbol{\Sigma}_{zz}\}$ 转化为sigmapoint表示

$$\mathbf{L}\mathbf{L}^T = \boldsymbol{\Sigma}_{zz}$$

$$\mathbf{z}_0 = \boldsymbol{\mu}_z$$

$$\mathbf{z}_i = \boldsymbol{\mu}_z + \sqrt{L + \kappa} \text{col}_i \mathbf{L}$$

$$\mathbf{z}_{i+L} = \boldsymbol{\mu}_z - \sqrt{L + \kappa} \text{col}_i \mathbf{L}$$

c. 对每个 sigmapoint 展开为状态和观测噪声的形式

$$\mathbf{z}_i = \begin{bmatrix} \check{\mathbf{x}}_{k,i} \\ \mathbf{n}_{k,i} \end{bmatrix}$$

将每个sigmapoint代入非线性观测模型进行精确求解

$$\check{\mathbf{y}}_{k,i} = \mathbf{g}(\check{\mathbf{x}}_{k,i}, \mathbf{n}_{k,i}), \quad i = 0 \dots 2L$$

d. 将转换后的 sigmapoint 重新组合得到最终结果

$$\boldsymbol{\mu}_{y,k} = \sum_{i=0}^{2L} \alpha_i \check{\mathbf{y}}_{k,i}$$

$$\boldsymbol{\Sigma}_{yy,k} = \sum_{i=0}^{2L} \alpha_i (\check{\mathbf{y}}_{k,i} - \boldsymbol{\mu}_{y,k}) (\check{\mathbf{y}}_{k,i} - \boldsymbol{\mu}_{y,k})^T$$

$$\boldsymbol{\Sigma}_{xy,k} = \sum_{i=0}^{2L} \alpha_i (\check{\mathbf{x}}_{k,i} - \check{\mathbf{x}}_k) (\check{\mathbf{y}}_{k,i} - \boldsymbol{\mu}_{y,k})^T$$

其中

$$\alpha_i = \begin{cases} \frac{\kappa}{L + \kappa} & i = 0 \\ \frac{1}{2(L + \kappa)} & \text{others} \end{cases}$$

将这些式子带入到上面广义高斯滤波的校正步骤方程中，便完成了最终的校正步骤。




滤波器基本原理

7. 粒子滤波(PF)推导

1) 蒙特卡罗方法原理

蒙特卡罗本质是基于大数定律，主要包括3步：

- 1) 根据输入的概率密度采集样本；
- 2) 通过非线性函数对每个样本进行转换；
- 3) 从转换的样本中重新计算概率密度。



蒙特卡罗方法原理示意图



滤波器基本原理

7. 粒子滤波(PF)推导

2) 粒子滤波原理

a. 从由先验和运动噪声的联合概率密度中抽取 M 个样本

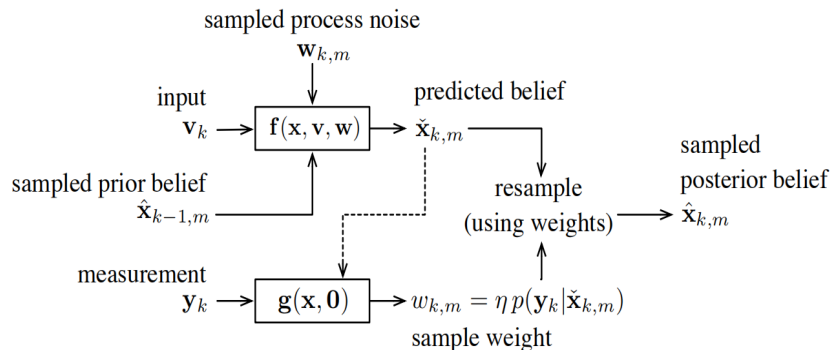
$$\begin{bmatrix} \hat{\mathbf{x}}_{k-1,m} \\ \mathbf{w}_{k,m} \end{bmatrix} \leftarrow p(\mathbf{x}_{k-1} | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{1:k-1}) p(\mathbf{w}_k)$$

其中, m 为唯一的粒子序号。

b. 使用 \mathbf{v}_k 得到后验概率分布函数的预测, 可以将每个先验粒子和噪声样本代入非线性运动模型,

$$\tilde{\mathbf{x}}_{k,m} = \mathbf{f}(\hat{\mathbf{x}}_{k-1,m}, \mathbf{v}_k, \mathbf{w}_{k,m})$$

这些新的“预测粒子”共同近似刻画了概率密度 $p(\mathbf{x}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{1:k-1})$ 。





滤波器基本原理

8. 粒子滤波(PF)推导

2) 粒子滤波原理

c. 结合 \mathbf{y}_k 对后验概率进行校正，主要分两步：

第1步，根据每个粒子的期望后验和预测后验的收敛程度，对每个粒子赋予权值；

$$w_{k,m} = \eta p(\mathbf{y}_k \mid \check{\mathbf{x}}_{k,m})$$

其中 η 为归一化系数。

在实践中，通常使用非线性观测模型来模拟期望的传感器读数，

$$\check{\mathbf{y}}_{k,m} = \mathbf{g}(\check{\mathbf{x}}_{k,m}, \mathbf{0})$$

假设 $p(\mathbf{y}_k \mid \check{\mathbf{x}}_{k,m}) = p(\mathbf{y}_k \mid \check{\mathbf{y}}_{k,m})$ ，其中等式右边的概率已知。

第2步，根据赋予的权重，对每个粒子进行重要性重采样

$$\hat{\mathbf{x}}_{k,m} \xleftarrow{\text{重要性重采样}} \{\check{\mathbf{x}}_{k,m}, w_{k,m}\}$$



滤波器基本原理

8. PF、EKF、UKF对比

举例对比三种方法的不同：以一维非线性函数 $f(x) = x^2$ 为例，其概率密度为 $\mathcal{N}(\mu_x, \sigma_x^2)$

1) 蒙特卡罗方法

根据输入密度获得的任意样本由下式给出

$$x_i = \mu_x + \delta x_i, \quad \delta x_i \leftarrow \mathcal{N}(0, \sigma_x^2)$$

将样本代入非线性函数中，可以得到

$$\begin{aligned} y_i &= f(x_i) \\ &= f(\mu_x + \delta x_i) \\ &= (\mu_x + \delta x_i)^2 \\ &= \mu_x^2 + 2\mu_x \delta x_i + \delta x_i^2 \end{aligned}$$

对式子两边求期望，可以得到输出的均值

$$\begin{aligned} \mu_y &= E[y_i] \\ &= \mu_x^2 + 2\mu_x \underbrace{E[\delta x_i]}_0 + \underbrace{E[\delta x_i^2]}_{\sigma_x^2} \\ &= \mu_x^2 + \sigma_x^2 \end{aligned}$$

同样的，我们可以推导出输出的方差

$$\begin{aligned} \sigma_y^2 &= E[(y_i - \mu_y)^2] \\ &= E[(2\mu_x \delta x_i + \delta x_i^2 - \sigma_x^2)^2] \\ &= \underbrace{E[\delta x_i^4]}_{3\sigma_x^4} + 4\mu_x \underbrace{E[\delta x_i^3]}_0 + (4\mu_x^2 - 2\sigma_x^2) \underbrace{E[\delta x_i^2]}_{\sigma_x^2} - 4\mu_x \sigma_x^2 \underbrace{E[\delta x_i]}_0 + \sigma_x^4 \\ &= 4\mu_x^2 \sigma_x^2 + 2\sigma_x^4 \end{aligned}$$

即，使用蒙特卡罗方法与无数个样本，闭式地求得后验概率的前两阶矩



滤波器基本原理

8. PF、EKF、UKF对比

2) 线性化方法

对非线性函数在输入概率密度的均值处进行线性化，
可得

$$\begin{aligned} y_i &= f(\mu_x + \delta x_i) \\ &\approx \underbrace{f(\mu_x)}_{\mu_x^2} + \underbrace{\frac{\partial f}{\partial x} \Big|_{\mu_x}}_{2\mu_x} \delta x_i \\ &= \mu_x^2 + 2\mu_x \delta x_i \end{aligned}$$

对等式两边取期望，得到

$$\mu_y = E[y_i] = \mu_x^2 + 2\mu_x \underbrace{E[\delta x_i]}_0 = \mu_x^2$$

对于输出的方差，有

$$\begin{aligned} \sigma_y^2 &= E[(y_i - \mu_y)^2] \\ &= E[(2\mu_x \delta x_i)^2] \\ &= 4\mu_x^2 \sigma_x^2 \end{aligned}$$



滤波器基本原理

8. PF、EKF、UKF对比

3) sigmapoint变换

在维度 $L = 1$ 的情况下, 有 $2L + 1 = 3$ 个 sigmapoint

$$x_0 = \mu_x$$

$$x_1 = \mu_x + \sqrt{1 + \kappa}\sigma_x$$

$$x_2 = \mu_x - \sqrt{1 + \kappa}\sigma_x$$

将每个 sigmapoint 代入非线性函数中, 得

$$y_0 = f(x_0) = \mu_x^2$$

$$y_1 = f(x_1)$$

$$= \left(\mu_x + \sqrt{1 + \kappa}\sigma_x\right)^2$$

$$= \mu_x^2 + 2\mu_x\sqrt{1 + \kappa}\sigma_x + (1 + \kappa)\sigma_x^2$$

$$y_2 = f(x_2)$$

$$= \left(\mu_x - \sqrt{1 + \kappa}\sigma_x\right)^2$$

$$= \mu_x^2 - 2\mu_x\sqrt{1 + \kappa}\sigma_x + (1 + \kappa)\sigma_x^2$$



滤波器基本原理

8. PF、EKF、UKF对比

3) sigmapoint变换

输出的均值为

$$\begin{aligned}
 \mu_y &= \frac{1}{1+\kappa} \left(\kappa y_0 + \frac{1}{2} \sum_{i=1}^2 y_i \right) \\
 &= \frac{1}{1+\kappa} \left(\kappa \mu_x^2 + \frac{1}{2} \left(\mu_x^2 + 2\mu_x \sqrt{1+\kappa} \sigma_x + (1+\kappa) \sigma_x^2 + \mu_x^2 - 2\mu_x \sqrt{1+\kappa} \sigma_x + (1+\kappa) \sigma_x^2 \right) \right) \\
 &= \frac{1}{1+\kappa} (\kappa \mu_x^2 + \mu_x^2 + (1+\kappa) \sigma_x^2) \\
 &= \mu_x^2 + \sigma_x^2
 \end{aligned}$$

输出的方差为

$$\begin{aligned}
 \sigma_y^2 &= \frac{1}{1+\kappa} \left(\kappa (y_0 - \mu_y)^2 + \frac{1}{2} \sum_{i=1}^2 (y_i - \mu_y)^2 \right) \\
 &= \frac{1}{1+\kappa} \left(\kappa \sigma_x^4 + \frac{1}{2} \left(\left(2\mu_x \sqrt{1+\kappa} \sigma_x + \kappa \sigma_x^2 \right)^2 + \left(-2\mu_x \sqrt{1+\kappa} \sigma_x + \kappa \sigma_x^2 \right)^2 \right) \right) \\
 &= \frac{1}{1+\kappa} (\kappa \sigma_x^4 + 4(1+\kappa) \mu_x^2 \sigma_x^2 + \kappa^2 \sigma_x^4) \\
 &= 4\mu_x^2 \sigma_x^2 + \kappa \sigma_x^4
 \end{aligned}$$



滤波器基本原理


8. PF、EKF、UKF对比

4) 总结

蒙特卡罗: $\mu_y = \mu_x^2 + \sigma_x^2$ $\sigma_y^2 = 4\mu_x^2\sigma_x^2 + 2\sigma_x^4$

线性化: $\mu_y = \mu_x^2$ $\sigma_y^2 = 4\mu_x^2\sigma_x^2$

sigmapoint: $\mu_y = \mu_x^2 + \sigma_x^2$ $\sigma_y^2 = 4\mu_x^2\sigma_x^2 + \kappa\sigma_x^4$



- a. PF是精确度最高的，因为是无损的；
- b. UKF可以通过调整 k 的值，达到与PF一样的效果，而且效率更高；
- c. 线性化方法是有偏的，但是效率最高；

注意：实际应用中，应以模型的非线性程度和噪声分布来选择方法，不严重降低精度的情况下，选择效率和可靠性最高的。



目录



1. 滤波器作用



2. 概率基础知识



3. 滤波器基本原理



4. 基于滤波器的融合



5. 观测性与观测度分析

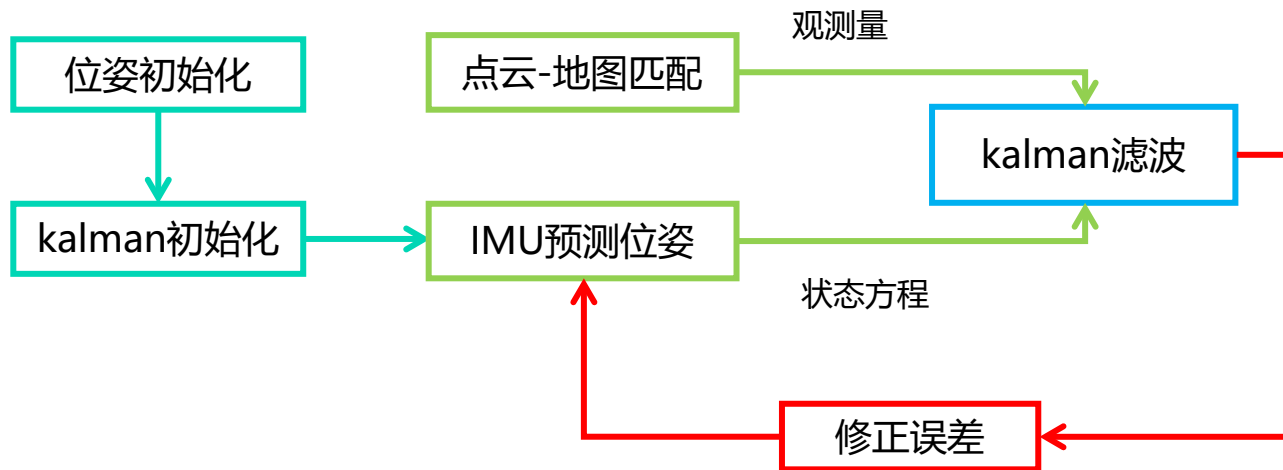


基于滤波器的融合

通过以上推导，滤波问题可以简单理解为“预测 + 观测 = 融合结果”。

结合实际点云地图中定位的例子，预测由IMU给出，观测即为激光雷达点云和地图匹配得到的姿态和位置。

融合流程用框图可以表示如下：





基于滤波器的融合

1. 基于误差状态的滤波

1) 状态方程

状态方程由误差方程得来，第三章已经完成误差方程的推导

$$\dot{\phi} = \phi \times \omega_{ie}^n - \delta\omega_{ib}^n$$

$$\delta\dot{V} = f^n \times \phi + \delta f^n$$

$$\delta\dot{P} = \delta V$$

为了写出完整的状态方程，需要把它们展开。

a) 姿态误差方程

由于

$$\phi = [\phi_E \quad \phi_N \quad \phi_U]^T$$

$$\omega_{ie}^n = [0 \quad \omega \cos L \quad \omega \sin L]^T$$

其中 $\omega = 7.292115e(-5)rad/s$ 为地球自转角速度

而

$$\delta\omega_{ib}^n = C_b^n \begin{bmatrix} \varepsilon_x \\ \varepsilon_y \\ \varepsilon_z \end{bmatrix}$$

其中 ε 为陀螺仪的bias。

因此，姿态误差方程 $\dot{\phi} = \phi \times \omega_{ie}^n - \delta\omega_{ib}^n$ 可重新写为

$$\begin{bmatrix} \dot{\phi}_E \\ \dot{\phi}_N \\ \dot{\phi}_U \end{bmatrix} = \begin{bmatrix} 0 & -\phi_U & \phi_N \\ \phi_U & 0 & -\phi_E \\ -\phi_N & \phi_E & 0 \end{bmatrix} \begin{bmatrix} 0 \\ \omega \cos L \\ \omega \sin L \end{bmatrix} - C_b^n \begin{bmatrix} \varepsilon_x \\ \varepsilon_y \\ \varepsilon_z \end{bmatrix}$$



基于滤波器的融合

1. 基于误差状态的滤波

1) 状态方程

b) 速度误差方程

由于

$$f^n = [f_E \ f_N \ f_U]^T$$
$$\delta f^n = C_b^n \begin{bmatrix} \nabla_x \\ \nabla_y \\ \nabla_z \end{bmatrix}$$

其中 ∇ 为加速度计的bias。

因此，速度误差方程 $\delta \dot{V} = f^n \times \phi + \delta f^n$ 可重新写为

$$\begin{bmatrix} \delta \dot{V}_E \\ \delta \dot{V}_N \\ \delta \dot{V}_U \end{bmatrix} = \begin{bmatrix} 0 & -f_U & f_N \\ f_U & 0 & -f_E \\ -f_N & f_E & 0 \end{bmatrix} \begin{bmatrix} \phi_E \\ \phi_N \\ \phi_U \end{bmatrix} + C_b^n \begin{bmatrix} \nabla_x \\ \nabla_y \\ \nabla_z \end{bmatrix}$$

c) 位置误差方程

位置误差方程 $\delta \dot{P} = \delta V$ 可直接展开

$$\begin{bmatrix} \delta \dot{P}_E \\ \delta \dot{P}_N \\ \delta \dot{P}_U \end{bmatrix} = \begin{bmatrix} \delta V_E \\ \delta V_N \\ \delta V_U \end{bmatrix}$$



基于滤波器的融合

1. 基于误差状态的滤波

1) 状态方程

在滤波器中，状态方程一般写为如下形式

$$\dot{X} = F_t X + B_t W$$

根据以上展开的误差方程，若令状态量

$$X = [\delta P^T \quad \delta V^T \quad \phi^T \quad \varepsilon^T \quad \nabla^T]^T$$

其中

$$\delta P = [\delta P_E \quad \delta P_N \quad \delta P_U]^T$$

$$\delta V = [\delta V_E \quad \delta V_N \quad \delta V_U]^T$$

$$\phi = [\phi_E \quad \phi_N \quad \phi_U]^T$$

$$\varepsilon = [\varepsilon_x \quad \varepsilon_y \quad \varepsilon_z]^T$$

$$\nabla = [\nabla_x \quad \nabla_y \quad \nabla_z]^T$$

则有

$$F_t = \begin{bmatrix} 0_{3 \times 3} & I_{3 \times 3} & 0_{3 \times 3} & 0_{3 \times 3} & 0_{3 \times 3} \\ 0_{3 \times 3} & 0_{3 \times 3} & F_{23} & 0_{3 \times 3} & C_b^n \\ 0_{3 \times 3} & 0_{3 \times 3} & F_{33} & -C_b^n & 0_{3 \times 3} \\ & & 0_{3 \times 15} & & \\ & & 0_{3 \times 15} & & \end{bmatrix}$$

其中

$$F_{23} = \begin{bmatrix} 0 & -f_U & f_N \\ f_U & 0 & -f_E \\ -f_N & f_E & 0 \end{bmatrix}$$

$$F_{33} = \begin{bmatrix} 0 & 0 & 0 \\ -\omega \sin L & 0 & 0 \\ -\omega \cos L & 0 & 0 \end{bmatrix}$$



基于滤波器的融合

1. 基于误差状态的滤波

1) 状态方程

在状态方程右侧，还包含 W ，它代表的是器件噪声，在惯导问题中

$$W = \begin{bmatrix} w_{gx} & w_{gy} & w_{gz} & w_{ax} & w_{ay} & w_{az} \end{bmatrix}^T$$

其中 w_g 为陀螺仪的噪声， w_a 为加速度计的噪声。

此时有

$$B_t = \begin{bmatrix} 0_{3 \times 3} & 0_{3 \times 3} \\ 0_{3 \times 3} & C_b^n \\ -C_b^n & 0_{3 \times 3} \\ 0_{6 \times 3} & 0_{6 \times 3} \end{bmatrix}$$



基于滤波器的融合

1. 基于误差状态的滤波

2) 观测方程

在滤波器中，观测方程一般写为

$$Y = G_t X + C_t N$$

此例中观测量有位置、失准角，则

$$Y = [\delta P^T \quad \phi^T]^T$$

由于

$$X = [\delta P^T \quad \delta V^T \quad \phi^T \quad \varepsilon^T \quad \nabla^T]^T$$

因此有

$$G_t = \begin{bmatrix} I_{3 \times 3} & 0_{3 \times 3} & 0_{3 \times 3} & 0_{3 \times 6} \\ 0_{3 \times 3} & 0_{3 \times 3} & I_{3 \times 3} & 0_{3 \times 6} \end{bmatrix}$$

$$C_t = \begin{bmatrix} I_{3 \times 3} & 0_{3 \times 3} \\ 0_{3 \times 3} & I_{3 \times 3} \end{bmatrix}$$

而此处 N 为观测噪声

$$N = [n_{P_E} \quad n_{P_N} \quad n_{P_U} \quad n_{\phi_E} \quad n_{\phi_N} \quad n_{\phi_U}]^T$$

注意，此处得到观测值 ϕ 的计算过程为：

先计算误差矩阵，

$$C_n^{n'} = C_b^{n'} (C_b^n)^T$$

其中 $C_b^{n'}$ 为当前时刻位姿的预测值，而 C_b^n 为姿态矩阵的观测值（此处指点云匹配得到的结果）。

而又根据下式，便可以得到 ϕ 。

$$C_n^{n'} \approx I - (\phi \times)$$



基于滤波器的融合

1. 基于误差状态的滤波

3) 构建滤波器

构建滤波器，即把融合系统的状态方程和观测方程应用到kalman滤波的五个公式中。

注：上面推导的方程是连续时间的，要应用于离散时间，需要按照采样时间对其进行离散化。

状态方程离散化，可以写为

$$X_k = F_{k-1}X_{k-1} + B_{k-1}W_k$$

其中

$$F_{k-1} = I_{15 \times 15} + F_t(\hat{X}_{k-1}, v_k, 0)T$$

$$B_{k-1} = B_t(\hat{X}_{k-1}, v_k, 0)T$$

其中， T 为kalman的滤波周期。

对于观测方程，不需要乘以滤波周期，可以直接写出

$$Y_k = G_kX_k + C_kN_k$$

将以上各变量，带入kalman滤波的五个方程，即

$$\check{X}_k = F_{k-1}\hat{X}_k + B_{k-1}W_k$$

$$\check{P}_k = F_{k-1}\hat{P}_{k-1}F_{k-1}^T + B_{k-1}Q_kB_{k-1}^T$$

$$K_k = \check{P}_kG_k^T(G_k\check{P}_kG_k^T + C_kR_kC_k^T)^{-1}$$

$$\hat{P}_k = (I - K_kG_k)\check{P}_k$$

$$\hat{x}_k = \check{x}_k + K_k(Y_k - G_k\check{X}_k)$$

重复以上过程，便可以持续得到传感器融合的位姿输出。



基于滤波器的融合

2. 基于导航信息的滤波

有些情况下，滤波的状态量不是使用误差量，而是直接使用导航信息，此时状态量为

$$X = [P^T \quad V^T \quad q^T \quad \varepsilon^T \quad \nabla^T]^T$$

1) 状态方程

导航信息的微分方程为

$$\dot{P} = V$$

$$\dot{V} = C_b^n(f^b + \nabla + \omega_a) + g^n$$

$$\dot{q} = \frac{1}{2}q \circ (w^b + \varepsilon + \omega_g)$$

其中, C_b^n 可以由四元数和旋转矩阵的关系得到。

$$C_b^n = \begin{bmatrix} C_{1,1} & C_{1,2} & C_{1,3} \\ C_{2,1} & C_{2,2} & C_{2,3} \\ C_{3,1} & C_{3,2} & C_{3,3} \end{bmatrix}$$

其中

$$C_{1,1} = q_0^2 + q_1^2 - q_2^2 - q_3^2$$

$$C_{1,2} = 2(q_1q_2 + q_0q_3)$$

$$C_{1,3} = 2(q_1q_3 - q_0q_2)$$

$$C_{2,1} = 2(q_1q_2 - q_0q_3)$$

$$C_{2,2} = q_0^2 - q_1^2 + q_2^2 - q_3^2$$

$$C_{2,3} = 2(q_2q_3 + q_0q_1)$$

$$C_{3,1} = 2(q_1q_3 + q_0q_2)$$

$$C_{3,2} = 2(q_2q_3 - q_0q_1)$$

$$C_{3,3} = q_0^2 - q_1^2 - q_2^2 + q_3^2$$



基于滤波器的融合

2. 基于导航信息的滤波

因此状态方程可以写成如下形式

$$\dot{X} = f(X, v, \omega, g^n)$$

它具有非线性，将其线性化可得

$$\dot{X} = F_t X + B_t W + \bar{f}(g^n)$$

此处

$$F_t = \begin{bmatrix} 0_{3 \times 3} & I_{3 \times 3} & 0_{3 \times 4} & 0_{3 \times 3} & 0_{3 \times 3} \\ 0_{3 \times 3} & 0_{3 \times 3} & F_{Vq} & 0_{3 \times 3} & C_b^n \\ 0_{4 \times 3} & 0_{4 \times 3} & F_{qq} & F_{q\varepsilon} & 0_{4 \times 3} \\ 0_{3 \times 3} & 0_{3 \times 3} & 0_{3 \times 4} & 0_{3 \times 3} & 0_{3 \times 3} \\ 0_{3 \times 3} & 0_{3 \times 3} & 0_{3 \times 4} & 0_{3 \times 3} & 0_{3 \times 3} \end{bmatrix}$$

$$\text{其中} \quad F_{Vq} = \frac{\partial [C_b^n(f^b + \nabla + \omega_a) + g^n]}{\partial q}$$

因此

$$F_{Vq} = \begin{bmatrix} F_{Vq0} & F_{Vq1} & F_{Vq2} & F_{Vq3} \\ -F_{Vq3} & -F_{Vq2} & F_{Vq1} & F_{Vq0} \\ F_{Vq2} & -F_{Vq3} & -F_{Vq0} & F_{Vq1} \end{bmatrix}$$

$$F_{Vq0} = 2 \left(q_0 \tilde{f}_x - q_3 \tilde{f}_y + q_2 \tilde{f}_z \right)$$

$$F_{Vq1} = 2 \left(q_1 \tilde{f}_x + q_2 \tilde{f}_y + q_3 \tilde{f}_z \right)$$

$$F_{Vq2} = 2 \left(-q_2 \tilde{f}_x + q_1 \tilde{f}_y + q_0 \tilde{f}_z \right)$$

$$F_{Vq3} = 2 \left(-q_3 \tilde{f}_x - q_0 \tilde{f}_y + q_1 \tilde{f}_z \right)$$

$$\tilde{f} = f^b + \nabla + \omega_a \quad \text{代表的是测量的加速度}$$



基于滤波器的融合

2. 基于导航信息的滤波

由第三章所述四元数相乘可转矩阵相乘的结论可知

$$F_{qq} = \frac{1}{2} \begin{bmatrix} 0 & -\tilde{\omega}_x & -\tilde{\omega}_y & -\tilde{\omega}_z \\ \tilde{\omega}_x & 0 & \tilde{\omega}_z & -\tilde{\omega}_y \\ \tilde{\omega}_y & -\tilde{\omega}_z & 0 & \omega_x \\ \tilde{\omega}_z & \tilde{\omega}_y & -\tilde{\omega}_x & 0 \end{bmatrix}$$

其中 $\tilde{\omega} = \omega + \varepsilon + w_g$ 代表的是测量的角速度

把四元数相乘转成矩阵相乘以后, 还可得

$$F_{q\varepsilon} = \frac{1}{2} \begin{bmatrix} -q_1 & -q_2 & -q_3 \\ q_0 & -q_3 & q_2 \\ q_3 & q_0 & -q_1 \\ -q_2 & q_1 & q_0 \end{bmatrix}$$

噪声项与前面基于误差状态的kalman一致, 即

$$W = [w_{gx} \ w_{gy} \ w_{gz} \ w_{ax} \ w_{ay} \ w_{az}]^T$$

因此状态方程函数 f 对噪声项求导可得

$$B_t = \begin{bmatrix} 0_{3 \times 3} & 0_{3 \times 3} \\ 0_{3 \times 3} & C_b^n \\ F_{q\varepsilon} & 0_{4 \times 3} \\ 0_{3 \times 3} & 0_{3 \times 3} \\ 0_{3 \times 3} & 0_{3 \times 3} \end{bmatrix}$$

而常数项保持不变

$$\bar{f}(g^n) = \begin{bmatrix} 0_{3 \times 1} \\ g^n \\ 0_{10 \times 1} \end{bmatrix}$$



基于滤波器的融合

2. 基于导航信息的滤波

2) 观测方程

以基于点云地图定位为例，观测为位置和姿态，即

$$Y = [P^T \ q^T]^T$$

因此观测方程如下

$$Y = G_t X + C_t N$$

其中

$$G_t = \begin{bmatrix} I_{3 \times 3} & 0_{3 \times 3} & 0_{3 \times 4} & 0_{3 \times 6} \\ 0_{4 \times 3} & 0_{4 \times 3} & I_{4 \times 4} & 0_{4 \times 6} \end{bmatrix}$$

由于观测量形式变化带来观测噪声形式变化，即

$$N = [n_{P_E} \ n_{P_N} \ n_{P_U} \ n_{q_0} \ n_{q_1} \ n_{q_2} \ n_{q_3}]^T$$

因此有

$$C_t = I_{7 \times 7}$$

至此，已知基于导航信息方法下连续时间的线性化状态方程和观测方程，连续时间方程计算离散时间方程的方法刚已经介绍。得到离散时间方程后，便可以直接使用kalman进行预测(IMU)和观测(点云匹配)的融合。

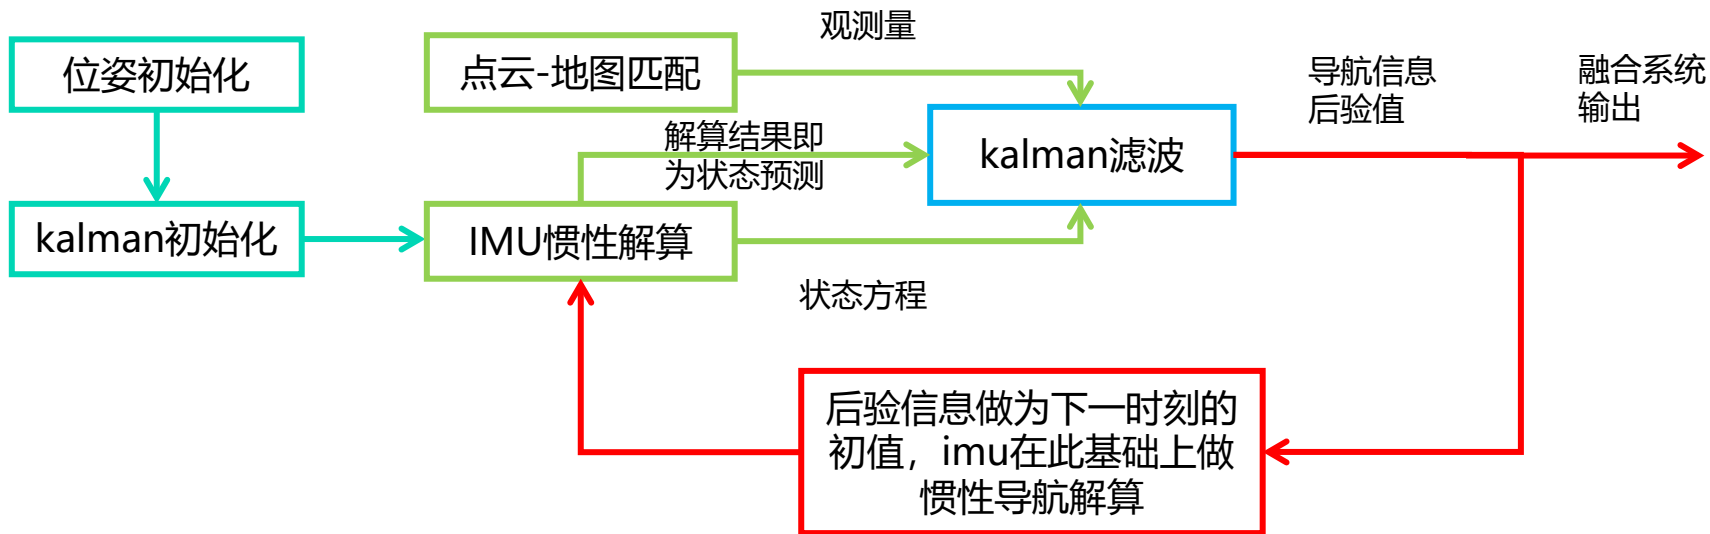


基于滤波器的融合

3. kalman滤波实际使用流程

1) 基于导航信息的kalman滤波流程

为了便于理解，先介绍基于导航信息的方法。

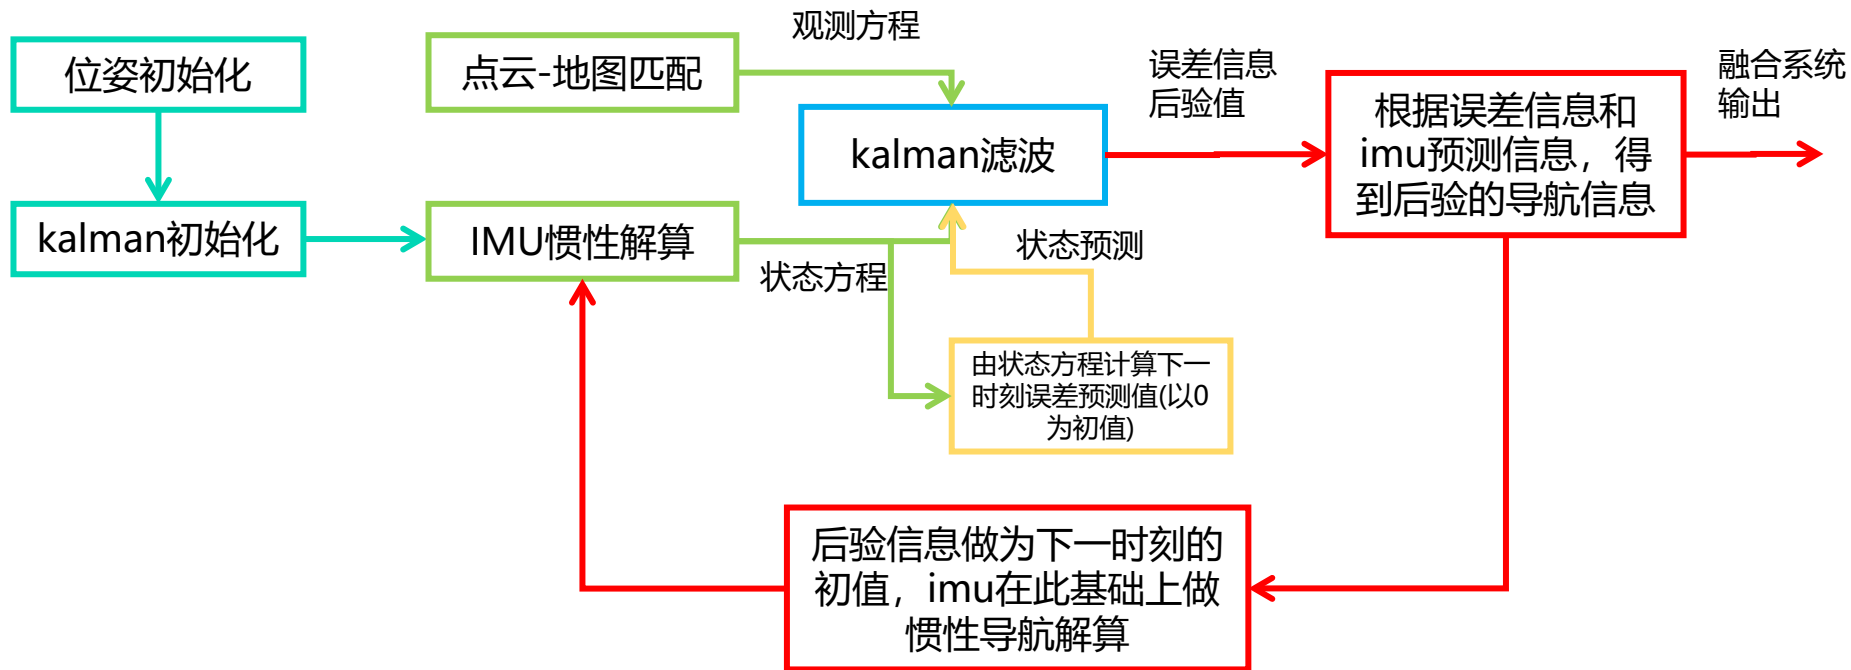




基于滤波器的融合

3. kalman滤波实际使用流程

2) 基于误差信息的kalman滤波流程





基于滤波器的融合

4. 一些讨论

1) 一般认为基于误差状态的kalman优于基于导航信息的kalman，理由是：

- a. 误差状态自由度与实际位姿自由度相等，可避免过参数化；
- b. 误差状态总是在0附近，因此线性化会更准确；
- c. 误差状态是小量，因此二阶项可以直接忽略，方便雅可比计算；
- d. 早期计算精度不高时，误差量相对于导航信息是小量，因此使用导航信息做状态时会被计算精度吃掉。

2) 惯性器件精度较高时，状态修正频率可以小于kalman滤波频率。



目录



1. 滤波器作用



2. 概率基础知识



3. 滤波器基本原理



4. 基于滤波器的融合



5. 观测性与观测度分析



观测性与观测度分析

1. 理解可观测性

以一个简单的方程组为例子

$$\begin{cases} x_1 + x_2 = 1 \\ x_1 + 2x_2 = 1 \end{cases}$$

显而易见，该方程组有解。

若令

$$X = [x_1 \ x_2]^T$$

$$Y = [1 \ 1]^T$$

并分别以他们为状态量和观测量构建kalman方程，
则该模型是“完全可观测的”。

相反，若有以下方程组

$$\begin{cases} x_1 + x_2 = 1 \\ 2x_1 + 2x_2 = 2 \end{cases}$$

若以它为基础构建kalman，则该模型是“不完全可观测的”。

一个模型的“可观测性”指的是能否由它的模型反推出状态。区分一个方程是否满足可观测的方法即看它的系数矩阵是否满秩。



观测性与观测度分析

2. 理解可观测度

仍以可观测的方程组为例，现在额外考虑了观测噪声，

$$\begin{cases} x_1 + x_2 = 1 + w_1 \\ x_1 + 2x_2 = 1 + w_2 \end{cases}$$

它的解为

$$\begin{cases} x_1 = 1 + 2w_1 - w_2 \\ x_2 = w_2 - w_1 \end{cases}$$

由于噪声是随机值，因此两个变量解的误差范围可以表示为

$$\begin{cases} \delta x_1 \leq |2w_1| + |w_2| \leq 3w \\ \delta x_2 \leq |w_2| + |w_1| \leq 2w \end{cases}$$

现在我们考虑另外一个方程组，

$$\begin{cases} x_1 + x_2 = 1 + w_1 \\ 2x_1 + x_2 = 1 + w_2 \end{cases}$$

按照同样的方式，可得到两个变量解得取值范围为

$$\begin{cases} \delta x_1 \leq 2w \\ \delta x_2 \leq 3w \end{cases}$$

可见，虽然两个方程都完全可观测，但变量解得精确范围却不同，即他们的“可观测度”不同。



观测性与观测度分析

2. 理解可观测度

判断可观测度的方法多种多样，其中一种常见的方法是SVD分解。

首先把方程写成如下形式

$$Y = AX$$

对系数矩阵进行SVD分解可得

$$A = U\Sigma V^T$$

其中 Σ 为奇异值构成的对角阵，即

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix}$$

且有

$$\sigma_1 \geq \sigma_2$$

奇异值越大，变量的可观测度就越强。

按照这种方式，对上面两个例子进行SVD分解。

第一个例子，有

$$\Sigma = \begin{bmatrix} 2.618 & 0 \\ 0 & 0.382 \end{bmatrix}$$

但是对于第二个例子，同样有

$$\Sigma = \begin{bmatrix} 2.618 & 0 \\ 0 & 0.382 \end{bmatrix}$$

原因是，奇异值是按照大小顺序排列，并不是按照与状态量同样的顺序排列，因此我们只能知道在一个系统里，各变量的观测度差异有多少，但是却不知道那个状态量是精度更高的那个。



观测性与观测度分析

2. 理解可观测度

为了解决上面的问题，可以进行如下分析

首先把方程写成如下形式

$$X = A^{-1}Y = (U\Sigma V^T)^{-1}Y$$

由于奇异值分解中的U和V都是正交矩阵，因此

$$X = A^{-1}Y = V\Sigma^{-1}U^TY$$

进一步，还可以展开为

$$X = \sum_{i=1}^2 \frac{u_i^T Y v_i}{\sigma_i}$$

其中有

$$U = \begin{bmatrix} u_1 & u_2 \end{bmatrix}$$

$$V = \begin{bmatrix} v_1 & v_2 \end{bmatrix}$$

上式表示，X的解被分解为多个解向量的和，即

$$X = X_1 + X_2 = \begin{bmatrix} x_{11} \\ x_{22} \end{bmatrix} + \begin{bmatrix} x_{12} \\ x_{22} \end{bmatrix}$$

带入具体的例子，比如例子1中，有

$$X_1 = \begin{bmatrix} 0.28 \\ 0.45 \end{bmatrix} \quad X_2 = \begin{bmatrix} 0.72 \\ -0.45 \end{bmatrix}$$

把奇异值和状态量对应的方法是，看 X_i 中哪个状态量的绝对值最大，那么该状态量对应的奇异值就是 σ_i 。

比如，在 X_1 中有 $0.45 > 0.28$ ，那么状态量 x_2 对应的奇异值就是2.618，同样可知，状态量 x_1 对应的奇异值是0.382，因此 x_2 的解精度更高，与之前的计算结果完全符合。



观测性与观测度分析

2. 理解可观测度

在第二个例子中，可以得到同样的结论。

$$X_1 = \begin{bmatrix} 0.45 \\ 0.28 \end{bmatrix} \quad X_2 = \begin{bmatrix} -0.45 \\ 0.72 \end{bmatrix}$$

可以看出，状态量 x_1 对应的奇异值就是2.618，同样可知，状态量 x_2 对应的奇异值是0.382，因此 x_1 的解精度更高，与之前的计算结果也同样符合。


为了定量评价，此处的奇异值即可以作为可观测度。



观测性与观测度分析

3. 理解SVD

对于SVD为何能起到这种效果，需要做出进一步解释，为了便于理解，此处给出一种直观但不严谨的方式表述这个问题。





观测性与观测度分析

3. 理解SVD

对M进行奇异值分解

$$\begin{aligned} M &= \begin{bmatrix} 1 & -2 \\ 1 & 2 \end{bmatrix} \\ &= \begin{bmatrix} -0.707 & -0.707 \\ 0.707 & -0.707 \end{bmatrix} \begin{bmatrix} 2.828 & 0 \\ 0 & 1.414 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \end{aligned}$$

M可以分解为两个部分

$$\begin{aligned} M &= \begin{bmatrix} -0.707 & -0.707 \\ 0.707 & -0.707 \end{bmatrix} \begin{bmatrix} 2.828 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} + \\ &\quad \begin{bmatrix} -0.707 & -0.707 \\ 0.707 & -0.707 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 1.414 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \end{aligned}$$


即把空间的变换拆分成了两次独立的变换，可以分开观察




观测性与观测度分析

3. 理解SVD

第一个奇异值对应的变换



第二个奇异值对应的变换






观测性与观测度分析

3. 理解SVD

因此变换的整个流程可以概括为下图



物理含义：矩阵对向量的投影，可以分解成多个方向投影的和，这些方向上向量的分量，构成解空间。

在可观测度分析中的意义：观测在各方向上都有投影，按某个奇异值投影之后，哪个变量对应的值最大，说明该奇异向量就是它的主方向，那么该奇异值就是它对应的奇异值了。

$$X = \sum_{i=1}^n \frac{u_i^T Y v_i}{\sigma_i}$$



观测性与观测度分析

4. 可观测性与可观测度的应用

1) 实际意义

可观测性:

在实际滤波模型中，当状态量较多或观测量较少时，会有部分状态量不可观测，这会导致滤波器不收敛，或收敛到一个错误的值上，并且对噪声的抗干扰性减弱，因此设计一个滤波模型后，需要对其进行可观测性分析。

可观测度:

当条件确实不能使所有状态量可观测时，应剔除不可观测的状态量，对模型进行裁剪。原因在于不可观测的状态量受噪声影响严重，并且会污染和它耦合的量。此外，对于多个均可观测的量，其可观测度不同，它们在kalman滤波中的收敛速度和收敛精度也会不同。



观测性与观测度分析

4. 可观测性与可观测度的应用

2) 定常系统可观测性分析

kalman滤波模型中的可观测性分析方法也由kalman本人发明，思路来源于他在现代控制理论中对系统模型进行的可观测性分析，二者形式上完全一致。

可观测性矩阵定义：

$$Q = \begin{bmatrix} G \\ GF \\ GF^2 \\ \vdots \\ GF^{n-1} \end{bmatrix}$$

其中 n 为滤波器维数。



Rudolf Kalman at his office in 1974.



观测性与观测度分析

4. 可观测性与可观测度的应用

2) 定常系统可观测性分析

可观测性矩阵的推导方法仍有多种，为了方便理解，此处仍选取解方程的思路来讲述。

在前述解方程的例子中，若能写成 $\dot{Y} = QX$ 的形式，则判断 Q 是否满秩，即可判断系统是否完全可观测。

kalman滤波的模型为

$$\begin{cases} \dot{X} = FX \\ Y = GX \end{cases}$$

该式本质上是一个微分方程，因此可以直接使用微分方程的解，即有

$$Y = Ge^{Ft}X(0) = QX(0)$$

指数函数可以泰勒展开，即

$$e^{Ft} = e^{\bar{F}} = 1 + \bar{F} + \frac{\bar{F}^2}{2!} + \frac{\bar{F}^3}{3!} + \dots$$

根据“卡莱-哈密顿定理”，因为 \bar{F} 是 n 阶方阵，因此对于 $\forall k \geq n$ ，必有

$$\bar{F}^k = a_0 + a_1\bar{F} + a_2\bar{F}^2 + \dots + a_{n-1}\bar{F}^{n-1}$$

因此，上面的指数函数必然能够写成下面的形式

$$e^{\bar{F}} = b_0 + b_1\bar{F} + b_2\bar{F}^2 + \dots + b_{n-1}\bar{F}^{n-1}$$

即

$$Q = \sum_{i=0}^{n-1} b_i G F^i = \begin{bmatrix} b_0 I & b_1 I & \dots & b_{n-1} I \end{bmatrix} \begin{bmatrix} G \\ G\bar{F} \\ \dots \\ G\bar{F}^{n-1} \end{bmatrix}$$



观测性与观测度分析

4. 可观测性与可观测度的应用

2) 定常系统可观测性分析

因此，当下式成立时，系统满足可观测性

$$\text{rank}(Q) = \text{rank}\left(\begin{bmatrix} G \\ G\bar{F} \\ \dots \\ G\bar{F}^{n-1} \end{bmatrix}\right) = n$$

3) 时变系统可观测性分析

在定位任务中，大部分系统的状态方程都是时变的，而上面的可观测性分析的推导只适合于定常系统。

此问题的解决办法是使用分段定常系统分析方法，即PWCS(Piece-Wise Constant Systems)，核心思路是把时变系统分成多个小的时间段，认为在每个时间段内是定常系统，随后找到整个系统观测性和各定常系统观测性之间的联系，即可解决问题。

具体证明过程细节参见文献：

Observability Analysis of Piece-Wise Constant Systems



观测性与观测度分析

4. 可观测性与可观测度的应用

3) 时变系统可观测性分析

首先，通过简单例子理解该思想的核心。

假设在0时刻有方程

$$\begin{cases} x_1 + x_2 = 1 \\ 2x_1 + 2x_2 = 2 \end{cases}$$

该方程显然不可解。

假设在1时刻有如下方程

$$\begin{cases} x_1 + 2x_2 = 2 \\ 2x_1 + 4x_2 = 4 \end{cases}$$

显然也不可解。

但是如果把两个方程联立，那么就可以解出各状态量。

PWCS的本质思想，就是看多个时刻的方程组联立之后，状态量是否可解。只不过在kalman标准模型下，有更严谨的表达形式。



观测性与观测度分析

4. 可观测性与可观测度的应用

3) 时变系统可观测性分析

a. 首先把系统划分成不同的时间段，每个时间段内对应一组状态方程和观测方程

$$\begin{cases} \dot{X}(t) = F_i X(t) \\ Y(t) = G_i X(t) \end{cases} \quad i = 1, 2, \dots, r$$

第 i 时刻的可观测性矩阵可以表示为

$$Q_i = \begin{bmatrix} G_i \\ G_i F_i \\ G_i F_i^2 \\ \vdots \\ G_i F_i^{n-1} \end{bmatrix}$$



观测性与可观测度分析

4. 可观测性与可观测度的应用

3) 时变系统可观测性分析

b. 根据不同时刻观测性矩阵，构建时变系统总的可观测性矩阵(TOM)

$$Q_{TO}(r) = \begin{bmatrix} H_1 \\ H_1 F_1 \\ \vdots \\ H_1 F_1^{n-1} \\ \hline H_2 F_1^{n-1} \\ H_2 F_2 F_1^{n-1} \\ \vdots \\ H_2 F_2^{n-1} F_1^{n-1} \\ \hline \vdots \\ \hline H_r F_{r-1}^{n-1} F_{r-2}^{n-1} \cdots F_1^{n-1} \\ H_r F_r F_{r-1}^{n-1} F_{r-2}^{n-1} \cdots F_1^{n-1} \\ \vdots \\ H_r F_r^{n-1} F_{r-1}^{n-1} \cdots F_1^{n-1} \end{bmatrix} = \begin{bmatrix} H_1 \\ H_1 F_1 \\ \vdots \\ H_1 F_1^{n-1} \\ \hline \begin{bmatrix} H_2 \\ H_2 F_2 \\ \vdots \\ H_2 F_2^{n-1} \end{bmatrix} F_1^{n-1} \\ \hline \vdots \\ \hline \begin{bmatrix} H_r \\ H_r F_r \\ \vdots \\ H_r F_r^{n-1} \end{bmatrix} F_{r-1}^{n-1} F_{r-2}^{n-1} \cdots F_1^{n-1} \end{bmatrix} = \begin{bmatrix} Q_1 \\ Q_2 F_1^{n-1} \\ \vdots \\ Q_r F_{r-1}^{n-1} F_{r-2}^{n-1} \cdots F_1^{n-1} \end{bmatrix}$$



观测性与观测度分析

4. 可观测性与可观测度的应用

3) 时变系统可观测性分析

c. 简化总的可观测性矩阵，得到可观测性矩阵(SOM)

$$Q_{SO}(r) = \begin{bmatrix} Q_1 \\ Q_2 \\ Q_3 \\ \dots \\ Q_r \end{bmatrix}$$

根据定理(证明过程较复杂，感兴趣的可直接参考前面给出的论文)，在满足 $\text{Null}(Q_i) \subset \text{Null}(F_i) \quad (i = 1, 2, \dots, r)$ 的条件下，下式成立，

$$\text{Rank}(Q_{TO}(r)) = \text{Rank}(Q_{SO}(r))$$

即只要计算 $Q_{SO}(r)$ 的秩，就可以判断状态量是否完全可观测。



观测性与观测度分析

4. 可观测性与可观测度的应用

4) 可观测度分析

可观测度的分析方法与前述相同，还是使用SVD进行计算。

定常系统中用来SVD分解的矩阵是 Q ，时变系统中用来分解的矩阵是 Q_{SO} 。

需要注意的是，在下式中， Y 不是一个时刻的观测值，而是多个时刻的，以确保它和 u_i^T 的维度保持一致

$$X = \sum_{i=1}^n \frac{u_i^T Y v_i}{\sigma_i}$$

需要注意的是，在定位任务中，由于各状态量量纲不同（有的是速度误差，有的是姿态误差），因此需要进行归一化，修改可观测度的定义为 $\beta = \frac{\sigma_i}{\sigma_0}$ ，

其中 σ_i 为每个状态量对应的奇异值，而 σ_0 表示的是观测量（比如位置）对应的奇异值。当有多个观测量时，可选奇异值最大的那个。



观测性与观测度分析

5. 可观测性与可观测度分析总结

- 1) SVD分解计算可观测度的方法在理论上并不完全严谨，因此可用它做大致的判断，不必纠结细微的比较。
- 2) 可观测度分析还有很多其他方式，包括kalman方差阵进行奇异值分解等。每种方式都有其缺点，SVD是目前使用最广泛的方式。
- 3) 时变系统在单个时刻不可观测，而多个时刻联合起来就可以观测的现象在定位任务中非常普遍，具有明确的物理意义，跟多种现象相关，比如初始对准时要绕八字、停车时精度会逐渐变差等。这类现象更多的解释会放在下一章介绍。



作业

作业1：任选一种滤波模型和方法，在kitti数据集上，实现基于点云地图的融合定位。

作业2：

- 1) 推导组合导航(gps+imu)的滤波模型(相比于基于地图定位，只有观测方程发生了变化)，对静止、匀速、转向、加减速等不同运动状态下各状态量的可观测性和可观测度进行分析。
- 2) 使用第三章所述数据仿真软件，产生对应运动状态的数据，进行kalman滤波。
- 3) 统计kalman滤波中各状态量的收敛速度和收敛精度，并与可观测度分析的结果汇总比较。

注意：本章可观测性与可观测度分析的内容至关重要，很多现实中的现象都要靠它解释，而在解释之前，如果不能对它们和kalman估计的收敛情况之间的联系有直观认识，下一章介绍这些现象时会很难理解，因此建议大家及时完成文章作业。

感谢聆听 !
Thanks for Listening

